# УНИВЕРЗИТЕТ У БЕОГРАДУ МАТЕМАТИЧКИ ФАКУЛТЕТ



# Давид Гавриловић

# ДИСТРИБУИРАНА ОБРАДА ГЕОПРОСТОРНИХ ПОДАТАКА

мастер рад

### Ментор:

др Милена Вујошевић Јаничић, ванредни професор Универзитет у Београду, Математички факултет

# Чланови комисије:

др Саша Малков, ванредни професор Универзитет у Београду, Математички факултет

др Мирко Спасић, доцент Универзитет у Београду, Математички факултет

Датум одбране: 10. јун 2022.



**Резиме**: **ТООО** Фијуче ветар у шибљу, леди пасаже и куће иза њих и гунђа у оџацима. Ниџо, чежњиво гледаш фотељу, а Ђура и Мика хоће позицију себи. Људи, јазавац Џеф трчи по шуми глођући неко сухо жбуње. Љубави, Олга, хајде пођи у Фуџи и чут ћеш њежну музику срца. Боја ваше хаљине, госпођице Џафић, тражи да за њу кулучим. Хаџи Ђера је заћутао и бацио чежњив поглед на шољу с кафом. Џабе се зец по Хомољу шуња, чувар Јожеф лако ће и ту да га нађе. Оџачар Филип шаље осмехе туђој жени, а његова кућа без деце. Бутић Ђуро из Фоче има пун џак идеја о слагању ваших жељица. Џајић одскочи у аут и избеже ђон халфа Пецеља и његов шамар. Пламте оџаци фабрика а чађаве гује се из њих дижу и шаљу ноћ. Ајшо, лепото и чежью, за љубав срца мога, дођи у Хаџиће на кафу. Хучи шума, а иза жутог цбуна и пања ђак у цвећу деље сеји фрулу. Гоци и Јаћиму из Бање Ковиљаче, флаша џина и жеђ падаху у исту уру. Цаба што Феђа чупа за косу Миљу, она јури Живу, али њега хоће и Даца. Док је Фехим у џипу журно љубио Загу Чађевић, Циле се ушуњао у ауто. Фијуче кошава над оџацима а Иља у гуњу журећи уђе у суху и топлу избу. Боже, џентлмени осећају физичко гађење од прљавих шољица! Дочепаће њега јака шефица, вођена љутом срџбом злих жена. Пази, геџо, брже однеси шефу тај ђавољи чек: њим плаћа цех. Фине џукце озлеђује бич: одгој их пажњом, стрпљивошћу. Замишљао би кафеџију влажних прстића, црњег од чађи. Траче, уштеду плаћај жаљењем због џиновских цифара. Џикљаће жалфија између тог бусења и пешчаних двораца. Зашто гђа Хаџић лечи живце: њена љубав пред фијаском? Јеж хоће пецкањем да вређа љубичастог џина из флаше. Џеј, љубичаст зец, лаже: гађаће одмах поквашен фењер. Плашљив зец хоће јефтину дињу: грожђе искамчи џабе. Џак је пун жица: чућеш тад свађу због ломљења харфе. Чуј, цукац Флоп без даха с гађењем жваће стршљена. Ох, задњи шраф на џипу слаб: муж гђе Цвијић љут кочи. Шеф џабе звиждуће: млађи хрт јаче кљуца њеног пса. Одбациће кавгаџија плаштом чађ у жељезни фењер. Дебљи кројач: згужвах смеђ филц у тањушни џепић. Џо, згужваћеш тихо смеђ филц најдебље крпењаче. Штеф, бацих сломљен дечји зврк у џеп гђе Жуњић. Дебљој згужвах смеђ филц — њен шкрт џепчић.

**Кључне речи**: анализа, геометрија, алгебра, логика, рачунарство, астрономија

# Садржај

1	Уво	од	1		
2	Програмски језик Скала				
	2.1	Особине језика <i>Scala</i>	2		
	2.2	Скала интерпретер	5		
	2.3	Типови	6		
	2.4	Променљиве	7		
	2.5	Контрола тока	8		
	2.6	Функције	8		
	2.7	Објектно оријентисана парадигма	11		
	2.8	Скала колекције	19		
	2.9	Поклапање образаца	24		
3	Дистрибуирана обрада података				
	3.1	Доба података	29		
	3.2	Скалирање система	30		
	3.3	Организација дистрибуираних система	31		
	3.4	Систем <i>Hadoop</i>	32		
	3.5	Дистрибуирани фајл систем <i>HDFS</i>	33		
	3.6	Парадигма $MapReduce$	36		
	3.7	Преговарач ресурса Apache Yarn	39		
	3.8	Остале компоненте <i>Hadoop</i> -a	42		
4	Aлат Apache Spark 44				
	4.1	Архитектура	44		
	4.2	Партиције	45		
	43	Апстракција података RDD	46		

### CAДРЖAJ

	4.4	Апстракција података <i>DataFrame</i>	53		
	4.5	Остале компоненте Спарка	56		
5	Скуп података $OpenStreetMap$				
	5.1	Елементи	59		
	5.2	Чворови	60		
	5.3	Путање	60		
	5.4	Релације	61		
6	$\mathbf{A}\mathbf{p}_{\mathbf{l}}$	o O	63		
	6.1	Opis	63		
	6.2	Cloud	63		
	6.3	Arhitektura aplikacije	63		
	6.4	Подаци	63		
	6.5	Obrada OSM skupa Sparkom	63		
	6.6	PolyContains	64		
	6.7	Rezultat	64		
7	Зак	льучак	65		
Бі	Библиографија (				

# Глава 1

# Увод

увод о свему у раду  $\mathbf{TODO}$ 

# Глава 2

# Програмски језик Скала

Скала (енг. Scala) је виши програмски језик заснован на функционалној и објектно оријентисаној парадигми. Име је добила од енглеске речи scalable јер је дизајнирана тако да се развија са потребама корисника. Има широк спектар примена и може се користити за писање једноставних скрипти али и у изградњи великих и комплексних система. [15]

Настала је 2001. на швајцарском федералном институту за технологију у Лозани (фра. École Polytechnique Fédérale de Lausanne) и њен творац је Мартин Одерски (енг. Martin Odersky). Прва званична верзија је изашла 20. јануара 2004. године.

Данас је широко распрострањена и користе је велике корпорације, као што су Twitter, Google и Apple. Поред тога, веома је заступљена у заједници отвореног кода у пројектима као што су Apache Spark, Apache Kafka, Apache Flink и Akka.

# 2.1 Особине језика *Scala*

Scala је спој две парадигме, објектно оријентисане и функционалне, па стога поседује велики број особина. Поред тога, компајлира се на исти начин као и језик Јава, са којим постоје одређене сличности.

# Објектно оријентисан и функционалан језик

Скала је у потпуности објектно оријентисан језик. То значи да је свака вредност која се дефинише објекат, као и да је свака акција која се позива

метод. На пример, уколико се врши одузимање два цела броја, позива се метод назван "-" (минус). Тај метод је дефинисан у класи која представља целе бројеве, Int. [15]

Поред тога што је објектно оријентисан језик, *Scala* је и функционалан језик. Функционално програмирање је засновано на два принципа. Први је да су функције вредности првог реда. То значи да се функције посматрају на исти начин као и други типови, на пример целобројни или ниска. Такође, функције је могуће прослеђивати другим функцијама, функције могу бити повратна вредност неке друге функције и функције се могу складиштити у променљивама.

Други принцип је да функције које се позивају немају бочне ефекте. Једна функција има улогу само да пресликава улаз у одговарајући излаз. То значи да ће сваки позив једне функције са истом вредношћу улазних аргумената, увек резултовати истом излазном вредношћу, независно од тога када се функција позива током извршавања програма. Другачији назив за ову особину је транспарентост референци. [15]

Из овога произилази да функционални језици користе имутабилне структуре података. То су такве структуре за које важи да се подаци унутар њих не мењају. Уколико до промене мора доћи, сама структура се не мења, већ се од ње конструише тотално нова, са измењеним вредностима. [15]

Међутим, Скала није чисто функционалан језик, што значи да се ипак може дефинисати функција која поседује бочне ефекте или се могу користити структуре података које се могу мењати. Поред тога, Скала омогућава писање функционалног кода без бочних ефеката и са имутабилним структурама података, па се може користити и на тај начин. [15]

# Повезаност са језиком Јава

Scala је конструисана тако да се компајлира у Јавин ЈВМ бајтко̂д (енг. Java JVM bytecode). То значи да Scala може користити Јава класе, методе и типове. На пример, Скалин објектни целобројни тип у својој имплементацији користи примитивни еквивалент из Јаве. Поред тога, Скала може користити Јава ко̂д и обогатити га на неки начин, као на пример додавањем неке методе у већ постојећу класу. Напоменимо и то да је време извршавања Скала програма приближно извршавању Јава програмима. [15]

Међутим, иако се компајлирају на исти начин, програми написани у језику Скала често садрже мањи број линија од оних написаних у језику Јава. У неким случајевима се очекује да је ко̂д чак дупло краћи. Краћи програми доводе до тога да је ко̂д лакше писати и разумети, али и до мање вероватноће прављења грешака. [15]

Један од многих примера како Скала смањује број линија у односу на Јаву је приказан у кодовима 2.1 и 2.2 који представљају начине декларисања класе у та два програмска језика.

```
// Java
class MyClass {
  private int index;
  private String name;

public MyClass(int index, String name) {
   this.index = index;
   this.name = name;
  }
}
```

Ко̂д 2.1: Декларација класе у језику Јава

```
// Scala
class MyClass(index: Int, name: String)
```

Ко̂д 2.2: Декларација класе у језику Scala

У Скали се не мора декларисати посебна конструктор фукција, што доводи до смањења броја линија кода. [15]

# Статичка типизираност

Статичка типизираност значи да се типови променљивих закључују за време компилације програма. То је супротно од динамичке типизираности која то чини за време извршавања. Оба приступа имају своје предности и мане. Скала је статички типизиран језик и поседује веома напредан систем типова.

То доноси предности које доводе до лакшег откривања грешака приликом писања кода. На пример, у статички типизираним програмима се током компилације сазнаје да ли је примењена нека операција на тип над којим та операција није дозвољена. Поред тога, статичка типизираност чини рефакторисање кода поузданијим. На пример, након измене метода се са сигурношћу може рећи да се повратни тип није променио. [15]

Скала није само статички типизиран језик већ је и језик који аутоматски закључује типове у току компилације. На пример, када се декларише нека променљива целобројног типа, нема потребе назначити и њен тип, пошто га компајлер може аутоматски одредити. То значи да се следеће две линије кода (пример 2.3) понашају еквивалентно. Исто важи и за било који други Скала тип, не само за целобројни.

```
// primer 1
val x: Int = 10

// primer 2
val x = 10
```

Ко̂д 2.3: Декларација типова

Скала програмер не мора експлицитно да наводи типове, али је то често пожељно због тога што се на тај начин осигурава да ће ко̂д заправо користити тип који му је намењен, али ће и побољшати читљивост и допринети документацији. [15]

# 2.2 Скала интерпретер

Скала је језик који се може интерпретирати. Да би се покренуо Скала интерпретер потребно је покренути команду scala.

```
$ scala
Welcome to Scala 2.13.6
Type in expressions for evaluation. Or try : help.
scala>
```

Ко̂д 2.4: Скала интерпретер

Након што се унесе ко̂д у интерпретер и притисне ентер, покреће се извршавање написаног кода и излаз се приказује у конзоли.

```
scala > 20 + 100

val res0 : Int = 120
```

Ко̂д 2.5: Пример кода у интерпретеру

Излаз покренуте команде је аутоматски генерисана променљива названа  $\mathbf{res0}$  типа Int у којој ће се налазити резултат унетог израчунавања. Новонастала променљива се може користити у наставку извршавања. [15]

```
scala > res0 + 100

val res1: Int = 220
```

Корд 2.6: Коришћење резултатских променљивих

Уколико је потребно само исписати вредност у конзоли без креирања нове променљиве може се користити функција print().

```
scala> print(20 + 100)
120
scala> print("Hello!")
Hello!
```

Ко̂д 2.7: Функција print

#### **2.3** Типови

Сви примитивни типови Јаве имају свој одговарајући еквивалент у Скали и када се типови у Скали компајлирају у Јавин бајтко̂д, превешће се баш у те типове. На пример, логички тип у Скали, scala.Boolean је еквивалент Јавином примитивном типу boolean. Исто важи и за друге примитивне типове Јаве попут Int, Float и Double. [15]

Поред њих постоје и уграђени сложени типови попут ниске (String), нторке (Tuple), низа (Array) и других. Како је Скала објектно оријентисан језик, могу се дефинисати и додатни типови уколико за тим има потребе, али о томе више речи у секцији 2.7.

Сваки тип, долази са скупом оператора који се на тај тип могу применити. Скала је написана тако да је сваки оператор заправо један метод дефинисан у класи која представља тип. Постоје различите врсте оператора попут аритметичких, логичких и битовских.

# 2.4 Променљиве

Постоје две врсте променљивих које се дефинишу кључним речима var и val. Разликују се по томе што се вредност променљивих дефинисаних са val не може мењати, док је код оних дефинисаних са var то могуће, све док је нова додељена вредност компатибилног типа. [15]

У наставку (примери 2.8, 2.9 и 2.10) су приказани примери дефиниција променљивих у Скала интерпретеру.

Ко̂д 2.8: Додељивање нове вредности val променљивима

```
scala > var x = 10
var x: Int = 10

scala > x = 20
// mutated x

scala > x
val res0: Int = 20
```

Ко̂д 2.9: Додељивање нове вредности var променљивима

Ко̂д 2.10: Додељивање некомпатибилног типа

# 2.5 Контрола тока

Скала поседује уграђене стандардне наредбе за контролу тока, *if* за гранање, *while* за петље и *for* и *foreach* за итерирање кроз колекције. У наставку су те наредбе приказане у скалиној синтакси. [15]

```
if (bool izraz) {
   // izraz je evalueiran true
} else {
   // izraz je evaluiran false
}

while (bool izraz) {
   // dok se izraz ne evaluira false
}

for (element <- kolekcija) {
   // operacije nad elementom
}

kolekcija.forach(funkcija koje se poziva za svaki element kolekcije)</pre>
```

Ко̂д 2.11: Контрола тока

# 2.6 Функције

Скала делом припада функционалној парадигми па су стога функције веома битан део језика. Функција се дефинише кључном речи def након које редом следе име функције, опциона листа њених аргумената са њиховим типовима раздвојених зарезом, тип повратне вредности функције, знак = и на крају тело функције. Пример дефиниције је приказан у коду 2.12.

```
def imeFunkcije(argument1: tip1, ...): povratni_tip = {
   // telo funkcije
```

```
}
```

Ко̂д 2.12: Дефиниција фунције у скали

У наставку је приказана функција која сабира два целобројна броја и враћа добијени резултат.

```
def saberi(x: Int, y: Int): Int = {
    x + y
}
```

Ко̂д 2.13: Пример функције

Последња линија тела функције ће увек бити њена повратна вредност али се поред тога она може назначити и наредбом return. Уколико се функција састоји од само једне линије кода, могу се изоставити витичасте заграде које означавају почетак и крај тела фунције. Поред тога, због закључивања типова се може изоставити и тип повратне вредности. Дакле, функција saberi() из претходног примера се краће може записати на следећи начин:

```
scala> def saberi(x: Int, y: Int) = x + y
def saberi(x: Int, y: Int): Int

scala> saberi(40, 2)
val res0: Int = 42
```

Ко̂д 2.14: Краћи запис функције saberi()

Тип повратне вредности се у неким случајевима ипак не сме изоставити. На пример, када се користи рекурзија. Такође, функција не мора да враћа никакву вредност. У том случају је повратни тип означен са *Unit*. [15]

Све функције су вредности првог реда у Скали па имају и свој тип. Тип функције је представљен заградама у којима се налазе типови њених аргумената након којих следи знак => праћен типом повратне вредности. Тип функције saberi() која поседује два аргумента типа Int, као и исти повратни тип ће бити:

```
(Int, Int) => Int
```

Ко̂д 2.15: Тип функције saberi()

Експлицитно навођење типова дозвољава декларацију функција вишег реда, функција које као аргументе имају друге функције. Пример 2.16 при-

казује функцију која као аргумент има функцију која има два аргумента и повратну вредност типа Int

Ко̂д 2.16: Функција вишег реда

Тип овог аргумента одговара типу функције saberi(), па се она може проследити ново написаној функцији.

```
scala > visiRed(saberi, 100, 200)

val res0: Int = 300
```

Ко̂д 2.17: Прослеђивање функције функцији

Све функције које су до сада приказане су поседовале идентификатор, односно име. Међутим, то није неопходно и могуће је дефинисати функцију без имена. Такве функције се називају ламбда функције (енг. *Lambda functions*).

Оне се обично користе када је нека функција потребна само једном, на пример у неком изразу, и не позива се никад више у коду. Декларишу се тако што се у заградама наводи низ аргумената са типовима, знак => и након тога повратна вредност. Пример ламбда функције која сабира два броја је приказан у наставку.

```
scala > (x: Int, y: Int) \Rightarrow x + y
val res0: (Int, Int) \Rightarrow Int = $Lambda$2582/1961424035@2207
eb9f
```

Ко̂д 2.18: Пример ламбда функције

Ламбда функције се могу проследити функцијама вишег реда, па претходно дефинисана функција visiRed() може бити позвана на следећи начин:

```
scala > visiRed((x: Int, y: Int) \Rightarrow x + y, 100, 200)
val res0: Int = 300
```

Ко̂д 2.19: Прослеђивање ламбда функције другој функцији

У овом примеру, функција saberi() је замењена ламбда функцијом истог понашања, што није довело до промене коначног резултата.

# 2.7 Објектно оријентисана парадигма

У овој секцији ће детаљније бити описана објектно оријентисана парадигма језика Скала.

#### Класе

Као и у Јави, у Скали класа представља нацрт преко ког се производе објекти. Да би се од класе креирао објекат, користи се кључна реч new.

Ко̂д 2.20: Дефиниција и инстанцирање класе у Скали

Унутар класе се дефинишу поља (енг. *fields*) и методе (енг. *methods*), који се заједно једним именом називају чланови (енг. *members*). Поља су променљиве које се дефинишу са *val* или *var* док су методи функције које описују неко понашање и дефинишу се на исти начин као и обичне функције. [15]

0

Ко̂д 2.21: Чланови класе

Сваком члану се додељује једно правило приступа којим се одређује опсег из ког се том члану може приступити. У Скали постоје три правила приступа и то су:

private, приступ унутар класе;

protected, приступ унутар класе и класа које наслеђују ту класу;

*public*, приступ изван класе (подразумевана вредност која се не наводи).

Пример *private* приступа је приказан у коду 2.22. Сваки покушај приступа приватној променљивој ван класе ће резултовати грешком.

Ко̂д 2.22: Пример private правила приступа

Поља се могу дефинисати ван тела класе, што је и Скалин стандард (кôd 2.23). Због тога се класа може написати уз помоћ мањег броја линија.

```
scala > val m = new MyClass
val m: MyClass = MyClass@5d8e4fa8
```

Ко̂д 2.23: Дефиниција поља ван тела класе

У претходном примеру, поље *field* поседује подразумевану вредност која ђе се том пољу увек доделити приликом инстанцирања класе. Међутим, она се не мора навести и, уколико је то случај, пољима се мора експлицитно доделити вредност приликом инстанцирања. Пример је приказан у коду 2.24. [15]

Ко̂д 2.24: Инстанцирање класе без подразумеваних вредности поља

# Наслеђивање

Наслеђивање се извршава на исти начин као у Јави, преко кључне речи extends. Инстанцирање поља надкласе из подкласе се дефинише у самој дефиницији наслеђивања, након extends (Пример 2.25). [15]

```
private val field: Int,
private val newField: Int
) extends MyClass(field) // prosledjivanje vrednosti
nadklasi
class MyExtendedClass

scala > val mec = new MyExtendedClass(10, 20)
val mec: MyExtendedClass = MyExtendedClass@42ba9b22
```

Ко̂д 2.25: Наслеђивање у Скали

Предефинисање чланова надкласе се врши на исти начин као у Јави, преко кључне речи override.

#### Апстрактне класе

Апстрактне класе се дефинишу коришћењем кључне речи abstract која се наводи пре речи class која означава класу, на исти начин као у Јави. [15]

Ко̂д 2.26: Апстрактна класа у Скали

Апстрактне класе се не могу инстанцирати, али се могу наследити од стране других класа.

Ко̂д 2.27: Инстанцирање апстрактне класе

#### Синглтон објекти

За разлику од Јаве, у Скали не постоје статичка поља. Уместо тога постоје синглтон објекти (енг. singleton object). Дефинишу се на исти начин као и класе, с тим што се користи кључна реч object уместо class. Добили су име по томе што представљају класу која има тачно једну инстанцу. Сви чланови објекта се могу посматрати као статички чланови у Јава класи. [15]

Ко̂д 2.28: Коришћење синглтон објекта

Уколико објекат дели своје име са неком класом, а при томе се налазе у истом фајлу, тај објекат се назива објекат пратилац (енг. companion object). Паралелно, та класа се назива класа пратилац тог објекта. Класа или објекат који су пратиоци могу да приступе приватним члановима свог пратиоца (ко̂д 2.29). [15]

```
object Kvadrat {
    def izracunajPovrsinu(a: Int) = a * a
}

class Kvadrat(a: Int) {
    def povrsina = Kvadrat.izracunajPovrsinu(a)
}

scala > val k = new Kvadrat(10)
val k: Kvadrat = Kvadrat@6cb2d5ea

scala > k.povrsina
val res0: Int = 100
```

Ко̂д 2.29: Пример пратиоца

#### Metog main()

Да би се Скала апликација покренула потребно је дефинисати објекат који у себи садржи main() метод. Тај метод представља улазну тачку у сваку Скала апликацију. [15]

Ко̂д 2.30: Пример main метода

#### Скала интерфејси

Основна јединица наслеђивања у Скали се назива *Trait*. Унутар њих се наводе поља и методи који се могу користити у класама које их имплементирају, односно наслеђују. Разлика између наслеђивања *trait*-а и класе је та што је дозвољено наследити једну класу, док је могуће наследити више од једног *trait*-а. Дефинишу се на исти начин као и класе с тим што се уместо кључне речи *class* користи реч *trait* (ко̂д 2.31). [15]

Унутар *trait*-а се декларишу и дефинишу поља и методи које класе које га имплементирају могу користити.

Ко̂д 2.31: Скала trait

Trait се додаје класи на исти начин као када се означава наследство, помоћу речи *extends*.

```
scala > class MyClass extends MyTrait
class MyClass
scala > val mc = new MyClass
val mc: MyClass = MyClass@774189d0
scala > mc.x
val res0: Int = 10
```

Ко̂д 2.32: Додавање trait-а класи

Уколико класа којој се додељује *trait* већ наслеђује неку класу или неки други *trait*, додељивање се мора извршити преко кључне речи *with*. Сваки нови *trait* који се додаје у овом случају се мора додати након нове речи *with*. Примери су приказани у коду 2.33. [15]

```
scala> class MyExtendedClass extends MyClass with MyTrait1
  with MyTrait2
class MyExtendedClass

scala> class MyExtendedTraits extends MyTrait1 with
  MyTrait2
class MyExtendedTraits
```

Ко̂д 2.33: Наслеђивање више *trait*-ова

Скала trait се може користити и као тип, а вредност променљиве тог типа мора бити класа која наслеђује тај trait.

```
scala> trait MyTrait
trait MyTrait

scala> class MyClass extends MyTrait
class MyClass

scala> val mc: MyTrait = new MyClass
val mc: MyTrait = MyClass@339cedbb
```

Kо̂д 2.34: Trait као тип

Из наведених карактеристика се може закључити да је Скала *trait* веома сличан Јавином интерфејсу, са разликом да *trait* може садржати и дефиниције метода и поља, а не само декларације. Међутим, *trait* је више од тога и унутар њега се може урадити све што се може урадити унутар Скала класе.

#### Case класе

У језику Скала, поред стандардних, постоји још једна врста класе названа *case* класа. Постоје три разлике између ове врсте класа и обичних:

- Променљиве ове класе се инстанцирају без кључне речи; new
- Свако поље ове класе мора имати префикс *val*;
- Case класа садржи аутоматски генерисане методе ==, toString() и hashCode().

```
scala > case class MyCaseClass(val field: Int)
class MyCaseClass

scala > val mcc = MyCaseClass(100)
val mcc: MyCaseClass = MyCaseClass(100)

scala > mcc.toString
val res0: String = MyCaseClass(100)
```

Ко̂д 2.35: Пример коришћења *case* класа

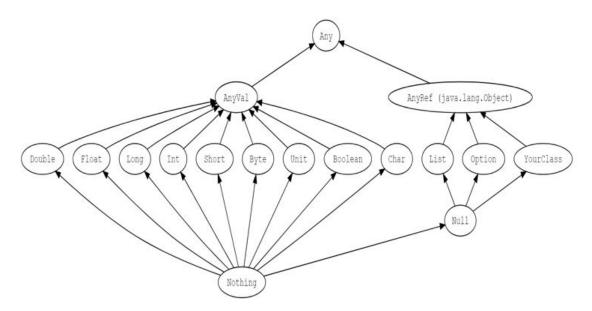
Једна од предности ових класа је та да се могу користити у конструкту специфичном за функционалне језике, поклапању образаца (енг. pattern matching), који ће бити детаљније описан у секцији 2.9. [15]

# Хијерархија класа

У Скали, као и у Јави, постоји хијерархија наслеђивања типова (слика 2.1). На врху се налази класа Any коју свака Скала класа наслеђује, имплицитно или експлицитно. Овај тип поседује два подтипа, AnyVal и AnyRef. Први је корен свим Скала типовима који представљају вредности. То су Byte, Short, Char, Int, Long, Float, Double, Boolean и Unit. Друга, AnyRef, представља

родитељску класу свим референцама у Скали, слично као класа *Object* у Јави. Потомци овог типа се инстанцирају преко кључне речи *new*. [15]

На дну референтних типова се налази класа *Null*. Вредност овог типа се може доделити било којој референци. Једина класа која наслеђује *Null* је *Nothing*. Класа *Nothing* нема вредност и не може се доделити ниједној променљивој.



Слика 2.1: Хијерархија Скала типова

# 2.8 Скала колекције

Скала поседује велики број уграђених колекција, мутабилних и имутабилних. Неке од њих су низови, листе, скупови и мапе.

#### Низови

Скала низ (енг. array) је мутабилна структура која представља низ података. Мутабилна је у смислу да се вредности елемената у низу могу мењати, док је број елемената фиксан. Сваки низ садржи елементе једног типа и може се креирати навођењем иницијалних елемената или његове дужине. Уколико се наведе дужина, сви елементи ће бити иницијализовани на подразумевану вредност жељеног типа. [15]

```
scala > val a1 = Array(1, 2, 3)
val a1: Array[Int] = Array(1, 2, 3)

scala > val a2 = new Array[Int](3)
val a2: Array[Int] = Array(0, 0, 0)
```

Ко̂д 2.36: Инстанцирање низа у Скали

У претходном примеру се у другом случају инстанцира нова класа коришћењем наредбе *new* док у првом то није случај. Разлог је тај што се у првом случају позива метод *apply()* који креира инстанцу низа. Поред тога, у првом случају је Скала компајлер аутоматски закључио тип низа на основу прослеђених елемената, док је у другом тип морао бити експлицитно назначен. [15]

Елементу низа се приступа слично као у Јави, са тим што се уместо угластих заграда користе обичне. На сличан начин се извршава и мењање једног елемента.

```
scala> val a = Array(1, 2, 3)
val a: Array[Int] = Array(1, 2, 3)

scala> a(0)
val res0: Int = 1

scala> a(0) = 100

scala> a
val res1: Array[Int] = Array(100, 2, 3)
```

Ко̂д 2.37: Приступ и измена елемента низа

#### Листе

Скала листе представљају имутабилну колекцију елемената истог типа. Разлика листе у Скали у односу на Јавину је та што је Скала листа увек имутабилна, док Јава листа може бити мутабилна.

Инстанцира се навођењем елемената. Приступ елементу листе се извршава на исти начин као и у случају низа. Пошто су листе имутабилне, измена вредности елемената није дозвољена. [15]

Ко̂д 2.38: Пример Скала листе

Спајање листи се извршава оператором :::. Приликом позива овог оператора се не извршава додавање елемената једне листе на другу, већ је резултат нова листа. Овај метод се може користити и за спајање више од две листе. [15]

```
scala > val | 1 = List(1, 2, 3)
val | 11: List[Int] = List(1, 2, 3)

scala > val | 12 = List(4, 5, 6)
val | 12: List[Int] = List(4, 5, 6)

scala > val | 13 = List(7, 8, 9)
val | 13: List[Int] = List(7, 8, 9)

scala > | 11 ::: | 12 ::: | 13
val | res0: List[Int] = List(1, 2, 3, 4, 5, 6, 7, 8, 9)
```

Ко̂д 2.39: Спајање листи

Нове листе се могу инстанцирати и коришћењем оператора ::, који као аргументе прима елемент и листу истог типа од којих конструише нову листу где елемент додаје на почетак листе.

```
scala > val \mid = List(1, 2, 3)

val \mid : List[Int] = List(1, 2, 3)
```

```
scala > 10 :: |
val res0: List[Int] = List(10, 1, 2, 3)
```

Ко̂д 2.40: Пример оператора ::

Коришћењем овог оператора се може извршити надовезивање елемената на празну листу (пример 2.41). У Скали се празна листа означава кључном речи Nil.

```
scala > val | = 1 :: 2 :: 3 :: 4 :: Nil 
val | List[Int] = List(1, 2, 3, 4)
```

Ко̂д 2.41: Додавање елемената на празну листу

#### Н-торке

Имутабилна колекција која садржи елементе различитог типа се назива н-торка (енг. Tuple). Ова структура података се може користити када је потребно вратити више различитих вредности функције. Tuple се инстанцира навођењем елемената између заграда. Елементу се приступа оператором  $\_X$  где је X редни број елемента унутар н-торке. [15]

```
scala> val t = (1, "string123", Array(1, 2, 3))
val t: (Int, String, Array[Int]) = (1, string123, Array(1, 2, 3))
scala> t._1
val res0: Int = 1
scala> t._3
val res1: Array[Int] = Array(1, 2, 3)
```

Ко̂д 2.42: Н-торка у Скали

# Скупови

Скуп је колекција за коју важи да садржи елементе истог типа, са тим што сваки елемент колекције мора бити јединствен. Постоје две врсте скупова, имутабилни (collection.immutable.Set) и мутабилни (collection.mutable.Set).

Инстанцирају се на исти начин као и низ, навођењем елемената. Уколико се током навођења наведе неки елемент више од једног пута, не добија се грешка, већ се дупликат аутоматски уклања. Елемент се додаје оператором +. Код мутабилних скупова + додаје елемент на постојећи скуп, док код имутабилних производи нови скуп са додатим елементом. [15]

```
scala > val s = Set(1, 1, 1, 1, 2, 2)
val s: scala.collection.immutable.Set[Int] = Set(1, 2)
```

Ко̂д 2.43: Инстанцирање скупа у Скали

#### Мапе

Мапе су колекције за рад са кључ-вредност паровима. Постоје мутабилне (collection.mutable.Map) и имутабилне (collection.immutable.Map). Имутабилне су подразумеване и користе се уколико се експлицитно не наведе супротно.

Дефинишу се навођењем низа кључ-вредност парова, раздвојених знаком – >. Сви кључеви и све вредности међусобно морају бити истог типа. Приступ вредностима се врши преко назива кључа, методом ().

Ко̂д 2.44: Мапе у Скали

Разлика између мутабилних и имутабилних мапа је та што је код мутабилних могуће изменити број елемената, као и саме елементе, док имутабилна мапа то не подржава.

```
// mutable map
scala > val mutableM = mutable.Map("k1" -> "v1")
val mutableM: scala.collection.mutable.Map[String, String] =
    HashMap(k1 \rightarrow v1)
scala> mutableM("k1") = "vred1"
scala> mutableM("k2") = "vred2"
scala > mutableM
val res0: scala.collection.mutable.Map[String, String] =
   HashMap(k1 \rightarrow vred1, k2 \rightarrow vred2)
// immutable map
scala > val immutableM = Map("k1" -> "v1")
val immutableM: scala.collection.Map[String, String] = Map(
   k1 \rightarrow v1
scala > immutableM("k1") = "vred1"
       error: value update is not a member of scala.
   collection. Map[String, String]
scala > immutableM("k2") = "vred2"
       error: value update is not a member of scala.
   collection.Map[String, String]
```

Ко̀д 2.45: Измена и додавање елемента код мутабилних и имутабилних мапа

# 2.9 Поклапање образаца

Поклапање образаца (енг. pattern matching) је честа карактеристика функционалних језика. Слична је наредби switch из Јаве, али нуди више могућности од ње. Састоји се од селектора, који представља израз или променљиву, кључне речи match и низа случајева унутар витичастих заграда. Сваки случај

се састоји од знака => који се налази између вредности са којом се селектор поклапа и кључне речи *case* са леве стране и израза који ће бити резултат поклапања са десне. [15]

```
selector match {
  case value1 => result1
  case value2 => result2
  case value3 => result3
  ...
}
```

Ко̂д 2.46: Поклапање образаца у Скали

Разлике између ове наредбе и Јавине наредбе *switch* су:

- *match* наредба увек резултује неком вредношћу;
- Када се пронађе одговарајућа вредност, друге вредности након ње се не разматрају. Није потребно користити наредбу *break*;
- Уколико ниједна вредност не одговара селектору, појављује се *MatchError*. То значи да увек треба покрити све могуће вредности селектора.

# Примери коришћења

Поклапање образаца је веома моћан механизам и користи се у великом броју случајева. Један од њих је поклапање константи:

```
val res2: String = the empty list
scala> describe(1001)
val res3: String = something else
```

Ко̂д 2.47: Поклапање константи

У претходном примеру се у последњем случају користи ознака \_. Назива се џокер (енг. wildcard) и поклапа се са било којом вредношћу селектора.

Ко̂д 2.48: Џокер у поклапању образаца

Поклапање образаца се користи и за поклапање променљивих. У примеру 2.49 променљива something одговара било којој вредности селектора, слично као џокер, али се преко ње та вредност преноси са десне стране ознаке =>. [15]

```
matched: some expression
```

Ко̂д 2.49: Поклапање променљивих

Поред вредности селектора, могуће је поклапати и његов тип, уколико је потребно имплементирати другачије понашање за другачије типове .

```
scala> trait MyTrait
trait MyTrait
scala > class MyClass 1 extends MyTrait
class MyClass 1
scala > class MyClass 2 extends MyTrait
class MyClass 2
scala > def describe(x: MyTrait) = x match {
         case mc1: MyClass 1 \Rightarrow "MyClass 1"
         case mc2: MyClass 2 => "MyClass 2"
         case _ => "some other class"
       }
def describe(x: MyTrait): String
scala > describe (new MyClass 1)
val res1: String = MyClass 1
scala > describe(new MyClass 2)
val res2: String = MyClass 2
```

Ко̂д 2.50: Поклапање типова

Могуће је комбиновати претходне примере и извршити поклапања типова и променљивих уз помоћ једног поклапања образаца. Пример 2.51 приказује функцију generalSize(x: Any) која се понаша другачије у односу на то ког типа је њен аргумент. [15]

```
def generalSize(x: Any): Int

scala> generalSize("some string")
val res1: Int = 11

scala> generalSize(12)
val res2: Int = -1
```

Ко̂д 2.51: Пример поклапања типова и променљивих

Поклапање конструктора се користи када је потребно извршити поклапање класа које наслеђују заједничку класу.

Ко̂д 2.52: Поклапање конструктора

# Глава 3

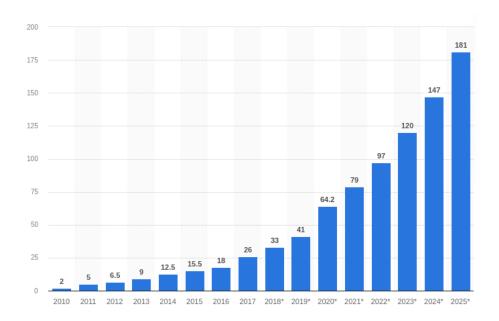
# Дистрибуирана обрада података

У последњих неколико година се генерише огромна количина података [14]. Друштвене мреже, видео садржај и куповина преко интернета на дневном нивоу производе петабајте података, а у будућности се очекује пораст тог тренда. Како је често проблем обрадити огромне количине података на једној машини, индустријски стандард су постали кластери који раде са подацима на дистрибуиран начин.

# 3.1 Доба података

Према истраживању [14] приказаном на једном од водећих интернет платформи за податке који се користе у пословању, *Statista*, количина података која се производи се тренутно може мерити у зетабајтима (милионима петабајта). Исто истраживање приказује да ће се наредних година тај број удвостручити. Приказ пораста тренда генерисања података је приказан на слици 3.1.

Корист података је огромна и велики број индустрија и компанија их користи на разне начине, од побољшања искуства корисника који користе њихове услуге, до разних предвиђања у пословању. Из тих разлога се доста улаже у складиштење, обраду, истраживање и анализу података. Подаци су се раније, док још увек нису генерисани у количинама у којима се то дешава данас, обрађивали на појединачним машинама, али се убрзо испоставило да такав приступ има своја ограничења.



Слика 3.1: Количина података по години у зетабајтима [14]

## 3.2 Скалирање система

У контексту система, скалирање означава могућност система да се прилагоди количини података који се уз помоћ њега обрађују. Постоје два начина скалирања уређаја који врше обраду података (слика 3.2). Први начин је вертикално скалирање (енг. vertical scaling) или scale-up [20]. У овом приступу се унапређује једна машина, на пример, додавањем веће количине меморије или појачавањем снаге процесора. Предност овог приступа је што се након унапређења машине не мора мењати логика апликација које се на њој извршавају. Али негативна особина је што постоји ограничење до ког се машина може унапредити, па стога постоји и ограничење у количини података које она може обрадити. Такође, у случају грешке, цео систем престаје са радом, пошто се састоји од само једне машине.

Други приступ је хоризонтално скалирање (енг. horizontal scaling) или scale-out [20]. У овом случају се не унапређује једна машнина, већ се, уколико је потребна додатна снага, додаје нова машина у систем. Добра особина овог приступа је што је често јефтиније додати неколико нових машина у систем него унапредити процесор неколико пута на истој машини. Још једна веома добра одлика је ефикасност. Када постоји неколико машина могуће је на свакој од њих обрађивати један део података, што је огромна предност у

односу на вертикално скалирање. Међутим, хоризонтално скалирање доноси додатан скуп проблема. Потребно је имплементирати цео систем, омогућити машинама да раде заједно и координисати их, као и обрадити грешке који се могу десити на појединачним машинама. Како су наведене предности значајне, а мане се могу превазићи, данашњи стандард у обради података је хоризонтално скалирање.



Слика 3.2: Врсте скалирања система

# 3.3 Организација дистрибуираних система

У оквиру хоризонталног скалирања свака машина у систему обрађује један део података и на тај начин доприноси коначном резултату, због чега машине морају да комуницирају једна са другом [20]. Поред тога, могуће је да постоје подаци који су потребни свим машинама у систему, што може довести до такмичења уређаја за приступ тим подацима. Уколико се подаци налазе на само једној машини у систему, све друге машине ће јој приступити, тако да су могућности система у том случају ограничене могућностима те једне машине којој све остале приступају. Поред тога, на тој машини се може догодити некакав проблем због ког она престане да функционише, што би изазвало престанак рада целог система.

Да би се потенцијални проблеми избегли, систем треба да функционише тако да уређаји који су у њему раде независно од других уређаја истог система, као и да престанак рада једне машине не утиче на систем у целини.

Другим речима, треба направити систем који очекује да се фаталне грешке дешавају.

У оваквим системима акценат је на софтверу, а не на хардверу и идеја је да се систем може направити од уређаја који су релативно јефтини и масовно доступни [20]. Такође, циљ је да се избегава премештање података међу уређајима, па се подаци, уколико је то могуће, обрађују на машини на којој се налазе.

# 3.4 Cuctem Hadoop

Први успешан систем који поседује претходно наведене карактеристике је развила компанија Google која је 2003. године објавила научни рад на ту тему [16]. У раду је представљен дистрибуирани фајл систем, назван Google file system или скраћено GFS. Систем је написан у програмском језику C++. Намена овог система је да се користи за складиштење великих количина података. Већ следеће године, Google је објавио нови научни рад о парадигми за ефикасну обраду велике количине података на кластеру [2]. Парадигма је названа MapReduce и њена намена је да се користи за обраду података складиштених у GFS-у.

Недуго након тога, уз помоћ научних радова компаније Google, настао је пројекат отвореног кода (енг. open source) назван Hadoop са идејом да имплементира карактеристике које поседују Google-ови GFS и MapReduce и да се као такав користи за складиштење и ефикасну обраду падатака на кластеру сачињеном од релативно јефтиних машина [20]. Највећи делови Hadoop система су Hadoop distributed file system, скраћено HDFS, и парадигма MapReduce који су заправо јавно доступни еквиваленти Google-ових технологија. Њихови логои су приказани на слици 3.3.

Укратко, *HDFS* је фајл систем који користи хоризонтално скалирање машина за складиштење огромних количина података [20]. Због боље поузданости користи репликацију, где се сваки фајл копира неколико пута и онда се те копије чувају на различитим уређајима у систему.

MapReduce је парадигма за обраду података, која се састоји из два дела названа Мар и Reduce, по којима је и добила име [20]. Улога Мар дела је да чита података из HDFS-а у деловима и трансформише их, док Reduce прикупља резултате обраде Мар фазе и спаја их у један. Обрада се извршава

на истим машинама HDFS-а на којима се подаци и налазе, чиме се избегава њихово премештање на неку другу машину.





Слика 3.3: Логои HDFS-а и MapReduce-а

Поред поменуте две компоненте, постоји и трећа, а то су *HDFS* апликације [21]. Оне се надовезују на *HDFS* и *MapReduce* тако што их користе за, редом, складиштење и обраду података. Најпознатије су *Apache Hive* [4] и *Apache Pig* [6], али поред њих постоје и многе друге, само мање заступљене. На слици 3.4 су приказане компоненте *Hadoop*-а.



Слика 3.4: Упрошћен приказ *Hadoop*-a

# 3.5 Дистрибуирани фајл систем *HDFS*

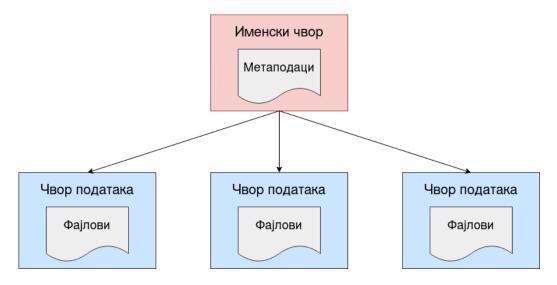
HDFS, скраћено од Hadoop distributed file system је дистрибуирани систем, што значи да складишти податке на више машина које ће се у даљем тексту звати чворови (енг. nodes). Скуп машина које раде заједно на такав начин да се могу посматрати као једна целина се назива кластер (енг. cluster).

#### Структура *HDFS*-а

Постоје две врсте чворова, именски чвор (енг. *name node*) и чвор података (енг. *data node*). Функционишу по водећи-зависни (енг. *master-slave*) архитектури, где именски чвор има улогу водећег. Чворови су приказани на слици 3.5.

Унутар *HDFS* система се налази један примарни именски чвор чија је улога да управља фајл системом и да регулише приступ подацима који се налазе на њему [9]. Он садржи информације о фајловима, као што су, између осталих, име, локација у систему где се фајл налази, последњи датум измене фајла као и правила приступа. Поред примарног, *HDFS* може имати и неколико секундарних именских чворова који представљају резервне копије.

Чворови података имају улогу да складиште фајлове система [9]. Поред тога, на овим чворовима се извршава обрада података. Чворови података су задужени за операције над фајловима као што су читање, мењање и брисање. Они ће извршити неку од тих операција само када им именски чвор то нареди.



Слика 3.5: Врсте чворова у *HDFS*-у

Уколико апликација жели да приступи *HDFS*-у, она ће прво комуницирати са именским чвором и од њега затражити фајлове који јој требају. Након тога, именски чвор проверава да ли та апликација поседује потребне дозволе за приступ тим фајловима и ако их она има, послаће јој њихову локацију у фајл систему. Након тога се може извршити жељени приступ.

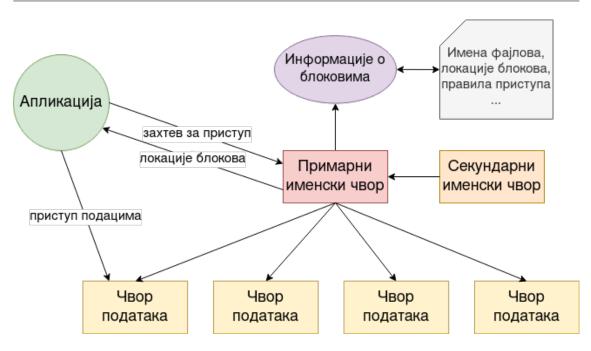
#### Основне карактеристике *HDFS*-а

Сваки фајл у *HDFS*-у је подељен на делове који се називају блокови чија је величина обично 128 мегабајта [9]. Блокови се често не налазе на истим чворовима у систему, што значи да се један фајл чува на неколико физички раздвојених машина. Ту може да настане проблем због тога што једна од тих машина може да се поквари и због тога престане са радом. У том сличају ће сви блокови складиштени на тој машини нестати. Да би се губљење фајлова избегло, *HDFS* сваки блок реплицира неколико пута и након тога оригинални блок и његове реплике распоређује по систему. Ако један од блокова фајла неочекивано нестане, увек је могуће приступити једној од његових реплика. Генерисане реплике се чувају на чворовима података, док се информације о томе ком фајлу реплике припадају налазе на именском чвору.

Блок ће се увек реплицирати одређен, фиксиран, број пута. Чворови података повремено шаљу сигнале именском чвору о доступности реплика. На тај начин ће именски чвор увек имати информацију о томе колико је пута сваки блок реплициран у систему и на основу тога може да, уколико тај број падне испод неке задовољавајуће вредности, направи нове реплике тог блока [9].

HDFS је конструисан тако да може да настави са радом у случају фаталних грешака на чворовима података. Међутим, могућа је појава грешака и на именском чвору и те грешке могу довести до пада целокупног система. Такви проблеми се решавају чувањем резервних копија именског чвора и због њих се у случају престанка његовог рада не губе информације. Резервне копије се праве у одређеним временским интервалима да би подаци на њима били ажурни. Резервне копије и репликација су битне за целокупну робусност система, односно поузданости података. Концепти HDFS-а су приказани на слици 3.6.

HDFS је систем за кога важи  $\bar{u}uuu$  једном, чи $\bar{u}aj$  више  $\bar{u}y\bar{u}a$  (енг. writeonce, read-many). Када се фајл постави унутар HDFS-а више се не може
мењати [20]. Уколико се фајл мора изменити долази до креирања новог
фајла који замењује стари. Иако такав приступ није ефикасан, апликације
које обрађују велике количине података се обично заснивају на томе да се
подаци не мењају, па се очекује да за променама неће бити потребе или ће
такви случајеви бити ретки. Такође, још једна од особина HDFS-а је да има
добре перформансе у случајевима када је потребан велики проток података,



Слика 3.6: Основне *HDFS* компоненте

на пример у случају читања великих фајлова.

# 3.6 Парадигма MapReduce

MapRreduce је парадигма која се користи за обраду података који су складиштени у HDFS-у [20]. Користи подели и завладај (енг. divide and conquer) приступ приликом обраде тако да више машина паралелно обрађује један део података.

Парадигма је заснована на концептима функционалног програмирања и функцијама које се често користе у обради низова и листи. Те фунције су *тар* и *reduce*. Прва од постојеће листе креира нову тако што на сваки елемент листе примени неку фунцију и од њега направи нови елемент. Друга од целе листе производи једну вредност. На истим принципима фунционише и *MapReduce*.

MapReduce обрађује податке у неколико фаза [21]. Прво, подаци се читају из HDFS-а и након тога прослеђују машинама које се зову мапери (енг. mappers). Те машине паралелно производе скуп привремених података који се након тога распоређују, сортирају и шаљу машинама које се зову редјусери (енг. reducers). Фаза која распоређује податке се назива фаза мешања

и сортирања (енг. shuffle and sort). Задатак редјусера је да приме подскуп података и да паралелно произведу једну вредност од истих. На самом крају се резултат свих редјусера комбинује и добија се резултат читавог MapReduce процеса, другачије названог и MapReduce задатак (енг. task). Могуће је, уланчавањем, комбиновати MapReduce задатке, тако да излаз из једног буде улаз у други. Скуп повезаних MapReduce задатака се назива MapReduce апликација.

#### MapReduce из аспекта функција

Из аспекта функција, map и reduce фазе се могу посматрати на следећи начин. Подразумевани формат је  $(\kappa h y u, epeghoc \overline{u})$  за који ће се због једноставности користити ознака (k, v). Током map фазе подаци се читају из HDFS-а и деле на делове на које се паралелно примењује функција map дефинисана од стране програмера. Паралелизам се постиже тако што се сваки део обрађује на засебној машини, маперу. Фаза map као улаз прима (k, v) парове и производи листу истог формата [21].

$$(k_1, v_1) \rightarrow map(k_1, v_1) \rightarrow list(k_2, v_2)$$

Након тога се листе генерисане од мапера групишу тако што се за сваки кључ прави једна група коју ће обрадити један редјусер. Овај део обраде је  $shuffle\ and\ sort.$ 

$$list(k_2, v_2) \rightarrow shuffleAndSort(k_2, v_2) \rightarrow k_2, list(v_2)$$

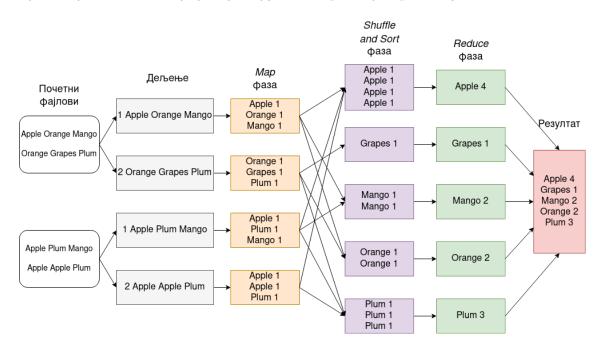
У последњој фази се на сваку од креираних група примењује функција reduce која производи једну вредност за сваку групу [21]. Овај процес је паралелизован и није могуће да се две групе података са различитим кључевима обрађују на истој машини у истом тренутку. Фаза Reduce прима кључ и листу вредности које му одговарају и као резултат производи једну вредност формата (k, v).

$$k_2, list(v_2) \rightarrow reduce(k_2, list(v_2)) \rightarrow (k_3, v_3)$$

Коначан резултат се добија комбиновањем резултата свих редјусера и може се уписати у *HDFS* или се искористити као улаз у други *MapReduce* задатак. У *MapReduce* апликацијама задатак програмера је да опише како ће се извршавати *map* и *reduce* фазе, док ће се *Hadoop* систем побринути

за све остало: читање података, сортирање, паралелизацију, координацију и извршавање послова [20].

Пример *MapReduce* апликације је приказан на слици 3.7 где је представљен процес пребројавања броја појављивања сваке речи у тексту. У приказаном примеру је улаз у мапере форматиран тако да је редни број линије фајла кључ, док је текст линије вредност. Улога мапера је да поделе текст на речи и да од њих направе листу парова формата (*peч*, 1). Након тога се парови који имају исту реч премештају на засебне редјусере који израчунавају колико пута се у почетном скупу појављује свака реч, сумирањем јединица.

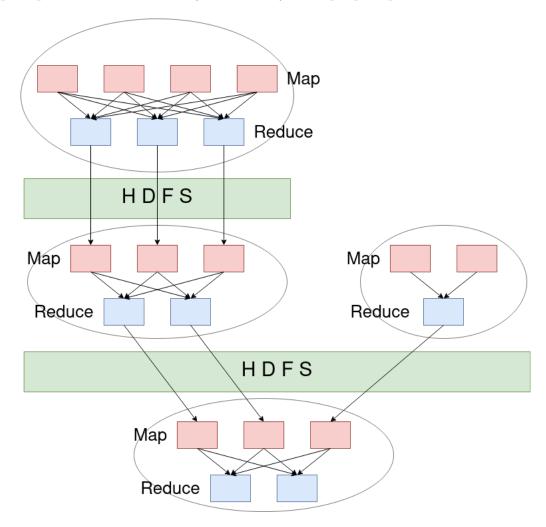


Слика 3.7: Пример MapReduce апликације

#### Недостаци MapReduce парадигме

MapReduce апликација се састоји од ланца MapReduce послова, таквих да излаз једног посла представља улаз у други (слика 3.8). Међутим, такав приступ има цену, а то је да се излаз генерисан од стране једног MapReduce посла чува унутар HDFS-а, одакле му приступају други MapReduce послови којима је тај излаз потребан [21]. Другим речима, међурезултати послова се чувају на диску, што ствара додатне улазно/излазне операције и тиме успорава извршавање целокупне апликације. Поред тога, унутар MapReduce

парадигме не постоји аутоматски начин да се послови заједно оптимизују, на пример комбиновањем, већ је за то задужен програмер.



Слика 3.8: Пример ланца MapReduce послова

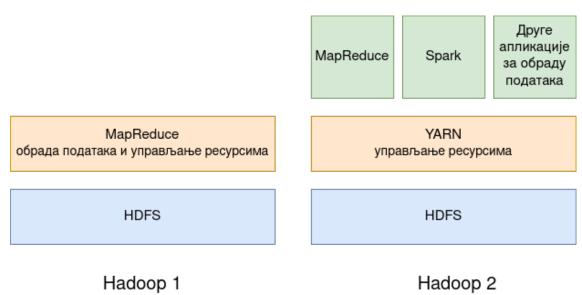
Због поменутих недостатака се *MapReduce* парадигма у данашње време ретко користи. Потиснута је од стране других технологија и алата, међу којима је и *Apache Spark* (поглавље 4).

# 3.7 Преговарач ресурса Apache Yarn

У првој верзији Hadoop-а, MapReduce је поред обраде великих количина података, за шта је примарно и намењен, имао додатне задатке, а то су заказивање MapReduce задатака и алокација и управљање ресурсима који су

MapReduce апликацији потребни [21]. Таква архитектура је знатно отежавала конструкцију апликација које користе MapReduce, па су због тога, у другој верзији Hadoop-а, одговорности MapReduce-а раздвојене. MapReduce је постао алат искључиво за обраду података, док је управљање ресурсима предато новој апликацији, са идејом да је MapReduce током извршавања користи.

Резултат је менаџер ресурса (енг. resource manager) отвореног кода назван Yarn [7] или yet another resource negotiator. Његова улога је да распоређује задатке апликација које користе Hadoop, али и да управља ресурсима који су тим апликацијама потребни [21]. Конструисан је да не буде специфичан само за MapReduce, већ пружа интерфејс ка Hadoop-у разним апликацијама међу којима је и Apache Spark. Разлика у архитектури у различитим верзијама Hadoop-а је приказана на слици 3.9.



Слика 3.9: Разлика у архитектури између *Hadoop* верзија

## Архитектура *Yarn*-а

Улога *Yarn*-а је искључиво да распореди извршавање задатака на кластеру и обезбеди им ресурсе потребне за њихово извршавање [21]. Све остало, попут надгледања система, праћења прогреса апликација, обраде грешака и сличног, је имплементирано у коду апликације која га користи.

Састоји је од две главне компоненте, менаџера ресурса (енг. resource manager) и од менаџера чворова (енг. node manager) [21]. Улога првог мена-

џера је да управља ресурсима читавог кластера, док други управља ресурсима машине на којој је покренут. То значи да ће кластер имати један менаџер ресурса и више менаџера чворова, по један за сваку машину у кластеру. Заједно, они управљају контејнерима (енг. container), апстракцијом меморије, процесорске снаге и улазно-излазних операција потребних да би се извршио један део апликације на кластеру.

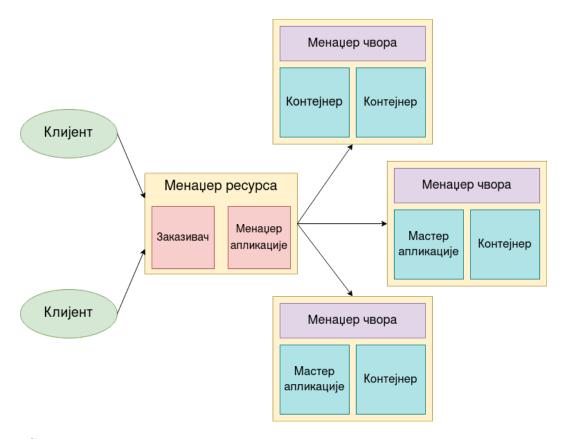
Менаџер ресурса је најбитнија компонента Yarn-а и одговоран је за извршавање сваке апликације на кластеру [21]. Састоји се од две компоненте, заказивача (енг. scheduler) и менаџера апликације (енг. application manager). Прва регулише распоред извршавања апликација, док друга прихвата апликације и преговара о алокацији првог контејнера који им је потребан.

Апликација која се покреће преко Yarn-а се састоји из два дела. Први је ко̂д који треба извршити на кластеру, док се други зове мастер апликације (енг. application master) [21]. Његова улога је да преговара о ресурсима и прати прогрес и статус апликације. Yarn нема информацију на који начин је успостављена комуникација између мастера апликације и кода који се извршава. Приказ архитектуре и компоненти Yarn-а у случају извршавања две апликације на кластеру је приказан на слици 3.10.

Процес покретања апликације преко *Yarn*-а се извршава следећим редоследом:

- 1. Клијент пријављује апликацију.
- 2. Менаџер ресурса алоцира контејнер на чвору у коме се покреће мастер апликације.
- 3. Мастер апликације се региструје код менаџера ресурса.
- 4. Мастер апликације преговара о контејнерима са менаџером ресурса. У исто време, заказивач распоређује извршавање делова апликације.
- 5. Мастер апликације комунуцира са менаџером чвора о покретању потребних контејнера за извршавање апликације.
- 6. Ко̂д апликације се извршава унутар контејнера.
- 7. Клијент преко менаџера ресурса и мастера апликације прати прогрес апликације.

8. Процес је завршен, мастер апликације се одјављује од менаџера ресурса.



Слика 3.10: Компоненте *Yarn*-а у случају извршавања две апликације

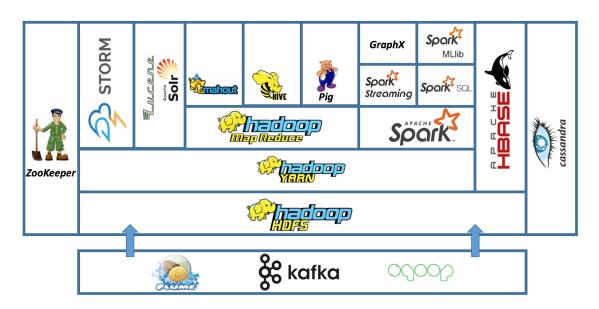
Yarn има одговорност да омогући правилно извршавање апликацијама које се извршавају на HDFS-у па стога мора обрадити грешке које се могу појавити [21]. На пример, могуће је да једна од машина у кластеру престане се радом и тако постане неупотребљива. Када се то деси, менаџер ресурса ће менаџер чвора на тој машини означити мртвим и неће га више разматрати. Исто ће се десити и са контејнерима те машине. Такође, сваки контејнер који почне да користи више ресурса од оних који су му омогућени ће бити уништен, да не би изазивао проблеме другим апликацијама у систему.

# 3.8 Остале компоненте *Hadoop*-a

Hadoop екосистем чини велики број апликација разних примена које на неки начин користе HDFS. Поред самог HDFS-а, MapReduce-а и Apache Yarn-а у њега спадају и Apache Kafka [5], апликација за рад са токовима података,

#### ГЛАВА 3. ДИСТРИБУИРАНА ОБРАДА ПОДАТАКА

Apache Pig [6] и Apache Hive [4], које се користе за обраду података и имплементиране су коришћењем MapReduce-а. Поред њих постоје, на пример, Presto [12], Apache Flume [3], Apache Zookeeper [8] али и многе друге. Приказ малог дела Hadoop екосистема је приказан на слици 3.11.



Слика 3.11: Део *Hadoop* екосистема

# Глава 4

# Алат Apache Spark

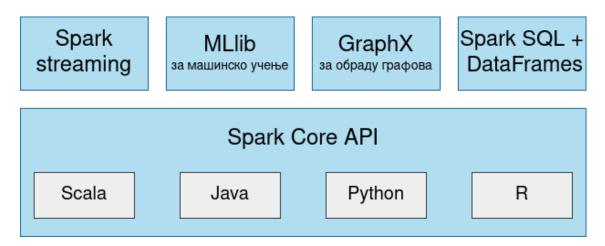
Apache Spark је алат отвореног кода. Настао је 2009. године на универзитету Беркли (енг. Berkeley) у Калифорнији. Написан је у програмском језику Скала и конструисан је са идејом да користи концепте функционалног програмирања. Постао је део Apache фондације 2013. године. Од тада су избачене три верзије, редом назване, Spark 1.0 (2013. године), Spark 2.0 (2016. године) и Spark 3.0 (2020. године).

Намењен је за дистрибуирану обраду велике количине података али се поред тога користи и за рад са токовима података (енг. streaming), машинско учење и рад са графовима [1]. Подржан је у програмским језицима Scala, Java, Python и R. Иако је намењен за рад над кластерима, може се користити и на једној машини. На слици 4.1 су приказане компоненте Apache Spark-а. У овој секцији ће детаљније бити приказане оне које се користе за обраду података.

## 4.1 Архитектура

Да би Spark могао да приступа кластеру, потребно му је омогућити приступ уз помоћ менаџера ресурса. Иако Spark поседује сопствени менаџер ресурса, могу се користити и други, попут  $Apache\ Yarn$ -а. Након повезивања је могуће покренути Spark апликације на кластеру.

Свака Spark апликација се састоји из једног драјвер процеса (енг. driver process) и једног или више извршилац процеса (енг.  $executor\ process$ ). Драјвер процес је срце Spark апликације и има три задужења:



Слика 4.1: Компоненте Apache Spark-a

- прикупљање информација о апликацији која се извршава;
- реаговање на програм апликације и њен унос;
- анализирање, распоређивање и планирање послова који се извршавају на извршиоцима.

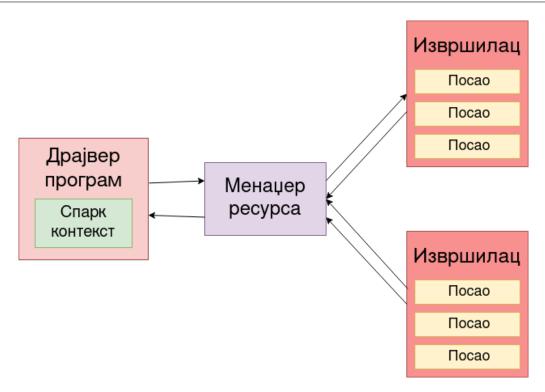
Изрвшиоци имају улогу да извршавају посао који им драјвер процес задаје. Поред тога, задужени су и за пријављивање стања извршавања тог посла драјверу.

Унутар драјвера постоји одвојен процес назван спарк контекст (енг. spark context) [1]. Његова улога је да дефинише конекцију ка кластеру. Такође се користи и за креирање апстракција  $Apache\ Spark$ -а названих RDD (поглавље 4.3). Једноставан приказ архитектуре Spark-а је дат на слици 4.2.

Архитектура је заснована на истим концептима, независно од тога да ли се *Spark* покреће у локалном моду, на једној машини, или на кластеру. Једина разлика је у томе што се на кластеру драјвер и извршиоци налазе на различитим машинама, док ће локално бити покренути на истој.

# 4.2 Партиције

Да би извршиоци могли паралелно да извршавају операције над подацима, Spark податке дели на делове који се називају партиције (енг. partitions) [1]. Партиција је део колекције података који се налази на једној машини



Слика 4.2: Архитектура Apache Spark-a

кластера. За партиције важи да се једна партиција увек обрађује од стране једног извршиоца, као и да један извршилац, у једном тренутку, обрађује податке тачно једне партиције.

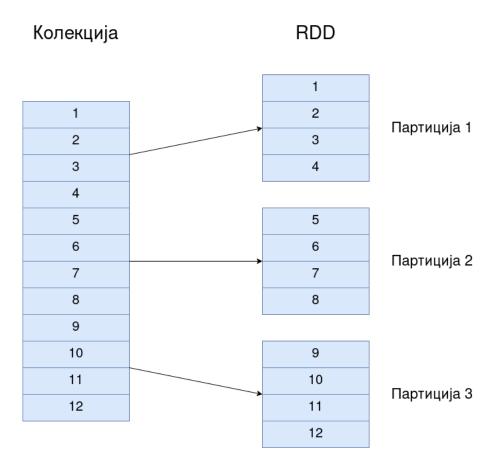
Уколико су подаци партиционисани само једном партицијом, биће обрађени од стране једног извршиоца у кластеру, независно од тога колико извршилаца постоји. Слично, уколико је креирано више партиција, али постоји само један извршилац, паралелизам неће постојати, због тога што постоји само једна машина која може обрадити податке.

# 4.3 Апстракција података RDD

Основна јединица рада у Spark-у се назива RDD, скраћено од resilient distributed dataset, и све операције са подацима се извршавају преко ње. RDD је колекција елемената за које важи да су партиционисани по машинама кластера и да се над њима паралелно могу извршавати операције [17]. Постоји неколико начина преко којих се RDD може креирати:

• Читањем неког фајла који се налази на фајл систему (обично HDFS);

- Од колекција података програмског језика у коме се користи *Spark* (слика 4.3). Процес дељења колекције у партиције се назива паралелизација;
- Од већ постојећег *RDD*-ја;
- Кеширањем постојећег *RDD*-ja.



Слика 4.3: Креирање *RDD*-ја од колекције података

Данас се RDD апстракција сматра застарелом и не користи се директно, већ постоје друге које су конструисане над њом и које су је потиснуле, углавном због бољих перформанси, попут  $Spark\ DataFrame$ -а (поглавље 4.4).

# Трансформације

Spark је конструисан по принципима функционалног програмирања, па су све његове структуре података имутабилне, што значи да се након њиховог

креирања не могу мењати [1]. Пошто се подаци не могу мењати, свака операција која треба да их измени заправо креира потпуно нову струкуру података. На пример, уколико постоји RDD којем се мењају подаци које садржи, они се неће изменити директно, већ ће се од постојећег RDD-ја направити нови који у себи саржи измењене податке.

Тај процес, где се од једног RDD-ја применом наредби добија други, се назива трансформација (енг. transformation) [1]. Пратећи функционалне концепте, трансформације немају бочне ефекте, што значи да се од једног RDD-ја применом истих трансформација, као резултат увек добија исти RDD, независно од тога када се те трансформације примењују. RDD који трансформацијом настаје од другог RDD-ја се назива зависни RDD (енг. dependency).


Постоје две различите врсте трансформација, уске (енг. narrow) и широке (енг. wide) [1]. За уске трансформације важи да једна партиција у почетном RDD-ју доприноси настајању највише једне партиције у зависном RDD-ју. Са друге стране, широке трансформације су такве где једна партиција почетног RDD-ја учествује у конструисању више партиција зависног RDD-ја, често свакој. Обе врсте трансформација су приказане на слици 4.4. Из приказане слике се за широку трансформацију може приметити да се подаци унутар једне партиције изворног RDD-ја премештају у сваку партицију зависног RDD-ја. Та појава се другачије назива мешање (енг. shuffle).

Постоји значајна разлика у перформансама узмеђу уских и широких трансформација [1]. Код уских, *Spark* извршава операције у меморији, док код широких пише резултате на диск и поново их распоређује по партицијама, што значајно успорава извршавање.

Све трансформације у *Spark*-у припадају лењој евалуацији што значи да се не извршавају док се њихова вредности не затражи [1]. За сваки ланац трансформација, *Spark* креира *ūлан шрансформација* који се извршава тек када је потребан њихов резултат. Разлог оваквог приступа је ефикасност. Уколико *Spark* поседује информацију о томе које ће се све трансформације извршити над структуром података, може оптимизовати цео процес на такав начин да добијање резултата траје најкраће могуће. Евалуација скупа трансформација се у *Spark*-у назива *акција* (секција 4.3).

# Уска трансформација

#### Широка трансформација



Слика 4.4: Приказ врста *Spark* трансформација

#### Примери *RDD* трансформација

У Spark-у постоји велики број трансформација, уских и широких. Неке од најпознатијих су приказане на слици 4.5 и то су:


**тар,** за сваки елемент почетног скупа података производи нови, применом неке операције;

**flatMap**, функционише исто као *map* с тим што сваки елемент почетног скупа произвноди нула, један или више елемената новог скупа;

filter, од постојећег скупа елемената производи нови у коме се налазе они елементи почетног скупа који задовољавају некакав услов;

**reduceByKey,** сабира вредности са заједничким кључем. Сабирање се иницијално извршава по партицији, након чега се подаци распоређују по новим партицијама и поново сабирају по кључу;

**join,** спаја два скупа елемената у један, где ће резултат бити скуп података у коме је вредност сваког кључа унија вредности тог кључа у засебним скуповима који учествују у спајању.



Слика 4.5: Примери *RDD* трансформација

Све *RDD* трансформације су део *Spark Core*-а [18]. Поред поменутих, постоје и *aggregate*, *union*, *intersect*, *mapValues*, *sortByKey* али и многе друге.

## Акције

Spark акције се користе када је потребно евалуирати резултат ланца трансформација [1]. Уколико је резултат акције нека вредност, она се прослеђује драјвер програму. Постоје три врсте акција:


- акције које приказују резултат у конзоли;
- акције које исписују резултат у излаз, на пример фајл;
- акције које пребацују податке у колекције програмског језика у коме се користи *Spark*.

Као и трансформације, RDD акције су део  $Spark\ Core$ -а [18]. Неке од најкоришћенијих акција су:

**count**, исписује број елемената у структури података; **saveAsTextFile**, чува податке унутар RDD-ја у текстуални фајл; **collect**, пребације све податке RDD-ја у колекцију програмског језика; **take**, пребацује првих N података RDD-ја у колекцију програмског језика.

#### Руковање грешкама

У току извршавања Spark трансформација могућа је појава грешака које могу да резултују губитком партиција. У том случају је Spark у могућности да их поврати помоћу механизма који се назива граф наследства (енг.  $lineage\ graph$ ) у коме се чувају информације о томе од ког RDD-ја је сваки RDD у ланцу трансформација настао и применом којих трансформација. Пример једног ланца Spark трансформација који у исто време представља и граф наследства је приказан на слици 4.6. Из примера се, на пример, може закључити да је  $RDD\_5$  настао спајањем  $RDD\_2$  и  $RDD\_4$ .



Слика 4.6: Пример једног *Spark* извршавања

Уз помоћ графа наследства *Spark* може да закључи од које партиције је настала свака партиција у ланцу и уколико нека од њих нестане, може је рекреирати [21]. У случају да нека партиција ланца није исправна, *Spark* ће проверити све партиције од којих је она настала. Уколико оне постоје, рекреираће неисправну партицију од њих, примењујући потребне трансформације. У супротном ће рекурзивно прегледати изворне партиције тих партиција и тај процес ће понављати све док се не пронађе исправна партиција или се не дође до партиције која је настала директним читањем са диска. У том случају ће је *Spark* поново прочитати и након тога покренути ланац трансформација из почетка.

Процес рекреације партиција је поуздан из два разлога. Први је што трансформације немају бочне ефекте, па ће се рекреирањем увек добити исти *RDD*. Други је што се изворни подаци чувају у *HDFS*-у, који је поуздан, па ће се у случају поновног читања из меморије и рекреирања читавог ланца, увек прочитати почетна, непромењена, вредност са диска.

#### Кеширање

Веома битна карактеристика Spark-а је могућност чувања података у меморији, односно кеширање [17]. Када се RDD кешира, свака машина у кластеру ће у својој меморији сачувати партиције које се на њој налазе и касније их користити у акцијама или трансформацијама у којима је тај RDD потребан, без извршавања целог ланца трансформација из почетка. Овакав приступ знатно побољшава перформансе Spark апликације.

RDD се може кеширати коришћењем функција cache и persist [17]. Чување у меморији се извршава тек након што RDD учествује у некој акцији. Кеширање је отпорно на грешке, и за рекреацију несталих партиција кешираног RDD-ја се користи граф наследства.

Поменуте функције омогућавају различите нивое кеширања у зависности од тога у којој врсти меморије се партиције чувају:

*cache*, кешира податке у меморији;

persist, са MEMORY ONLY аргументом кешира податке у меморији;

persist, са  $DISC\_ONLY$  аргументом кешира податке на диску. Овај приступ се не саветује из тог разлога што је често брже рекреирати цео ланац

трансформација из почетка, него учитати кеширан *RDD* са диска;

- **persist**, са  $MEMORY\_ONLY\_2$  аргументом кешира податке у меморији али поред тога извршава репликацију RDD-ја на још једну машину кластера;
- **persist,** са  $DISC\_ONLY\_2$  аргументом кешира податке на диску али поред тога извршава репликацију RDD-ја на још једну машину кластера;
- **persist**, са MEMORY\_AND\_DISC аргументом кешира податке у меморији уколико постоји довољно простора, а у супротном кеширање извршава на диску.

# 4.4 Апстракција података DataFrame

DataFrame је дистрибуирана колекција налик табели, са дефинисаним редовима и колонама [1]. Свака колона мора имати исти број редова и сваки ред мора имати исти број колона. Поред тога, свакој колони је додељен један тип ког морају бити све вредности које се у њој налазе.

Сваки Spark DataFrame садржи метаподатке који описују имена колона и њихове типове [1]. Ти метаподаци се називају шема (енг. schema). Шема се може дефинисати експлицитно али се може и аутоматски закључити из података који се налазе унутар DataFrame-а. Поред типова, у шеми се налази информација о томе да ли колона може поседовати null вредности. На слици 4.7 је приказан једноставан пример DataFrame-а и његове шеме.

# **DataFrame**

	Іема	
	IEIMA	

Име	Број индекса	Смер
Милица	1100	Математика
Петар	1101	Информатика

1	ne: string ble = false)
Број ин, (nulla	декса: integer ble = false)
1	ep: string ble = false)

Слика 4.7: Spark DataFrame и његова шема

У *Spark*-у постоји велики број типова који се могу доделити колонама *DataFrame*-а [1]. Постоје једноставни типови попут целобројних бројева, де-

цималних бројева и ниски али постоје и сложени, попут низова, мапа и датума. Сви *Spark* типови се могу мапирати у одговарајуће типове програмских језика у којима се он користи.

#### Трансформације и акције DataFrame-a

Све особине трансформација и акција које важе за апстракцију RDD, важе и за трансформације и акције DataFrame-а [1]. Дакле, трансформације немају бочне ефекте и лењо се евалуирају, тек када се позове акција. Поред тога, резултат трансформације примењене на DataFrame ће увек бити нови DataFrame. Једина разлика је у томе што RDD и DataFrame другачије представљају податке, па су им трансформације и акције другачије. Како је DataFrame сличан табели у релационим базама, поседује неколико трансформација које су идентичне наредбама у програмском језику SQL. Неке од најкоришћенијх DataFrame трансформација су приказане на слици 4.8 и то су:

select, конструише нови DataFrame са подскупом колона почетног;

*filter*, конструише нови *DataFrame* са оним редовима почетног који задовољавају задати услов;


with Column, конструише нови DataFrame додавањем колоне на почетни;

join, спаја два DataFrame-а у један на основу вредности колона.

Примери акција DataFrame-а су collect(), која трансформише DataFrame у струкуру података програмског језика у коме се Spark користи и show(), која се користи за испис DataFrame-а на стандардни излаз [1]. Поред њих постоје и многе друге.

## Разлика између DataFrame-а и RDD-ja

Поред различитог начина представљања података, постоји и знатна разлика у перформансама између *RDD*-ја и *DataFrame*-а [1]. *RDD* се користи за програмирање ниског нивоа, пошто омогућава директан рад са партицијама. Међутим, приликом писања *RDD* трансформација, програмер мора



Слика 4.8: Примери DataFrame трансформација

бити веома пажљив када и коју трансформацију примењује, због тога што редослед може значајно да утиче на перформансе.

Са друге стране, редослед примене трансформација *DataFrame*-а не утиче на брзину извршавања [1]. Разлог томе је што сваки *DataFrame* ко̂д пролази кроз аутоматски процес оптимизације, па ће добијени резултат увек бити најбржи могући. За оптимизацију је задужен процес који се зове *Catalyst*. Због перформанси, али и због једноставнијег интерфејса, *DataFrame* је скоро потпуно потиснуо *RDD* из уоптребе.


## Планови извршавања

Процес извршавања *DataFrame*-а укључује следеће кораке:

- 1. Ко̂д DataFrame-а је написан
- 2. уколико је исправан, од њега се прави логички план
- 3. Од логичког плана се конструише физички план, уз примену оптимизација
- 4. Добијени физички план се пребацује у RDD и извршава се

Ако је *DataFrame* ко̂д синтаксно исправан, од њега се конструише неразрешен логички план (енг. *unresolved logical plan*) који представља трансформације које треба извршити, али не садржи никакве информације о томе над којим табелама и колононама. Те информације се добијају уз помоћ каталога (енг. *catalog*) у коме се налазе информације о *DataFrame*-овима. Резултат примене каталога на неразрешен логички план је логички план (енг. *logical plan*). Након тога се он оптимизује од стране *Catalyst*-а, који оптимизује логички план тако што га анализира и примењује одређена правила оптимизације на њега. Резултат *Catalyst*-а је оптимизовани логички план (енг. *optimized logical plan*). [1]

Након што се оптимизовани логички план успешно креира, Spark у односу на њега конструише неколико физичких планова (енг. physical plan). Физички план дефинише на који начин и уз помоћ којих наредби ће се логички план извршити на кластеру. Сви физички планови се након тога евалуирају и бира се онај са најбољим перформансама. Тај физички план се преводи у RDD трансформације и ивршава на кластеру. Цео процес је приказан на слици 4.9. [1]



Слика 4.9: Ток извршавања Spark DataFrame-a

# 4.5 Остале компоненте Спарка

У Spark-у, поред RDD и DataFrame апстракције, постоје још две, DataSet и Spark SQL. Веома су сличне DataFrame-у и пролазе кроз исти процес извр-

шавања, али ипак постоје мање разлике између њих. [1]

 $Spark\ SQL$  се користи за извршавање SQL упита над подацима у кластеру. Једина разлика у односу на DataFrame је у томе што се синтаксне грешке SQL кода појављују тек када се ко̂д извршава, а не у компилацији, што је случај код DataFrame-а. [1]

Разлика између *DataSet*-а и *DataFrame*-а је у провери типова колона. Они се код *DataFrame*-а проверавају са онима у шеми у току извршавања програма, док се код *DataSet*-а то дешава за време компилације. Такође, разлика је у томе што је *DataSet* доступан само у *JVM* базираним језицима, Скали и Јави, док у другима не постоји. [1]

Уз помоћ *Spark*-а се могу конструисати модели машинског учења, преко *Spark MLlib* библиотеке. Она се може користити за препроцесирање, тренирање модела и прављење предвиђања. *Spark* поседује и библиотеку за рад са графовима, *GraphX*, али се за обраду графова на кластеру често користе друга решења. [1]

У Spark-у постоје и операције над токовима података. Могуће је закачити се за ток података и над њим примењивати исте трансформације као код DataFrame-а. Spark streaming омогућава претплату на токове података који настају из веб сокета (енг. web socket), локације у фајл систему или од стране Apache Kafka-e. [19]

# Глава 5

# Скуп података OpenStreetMap

OpenStreetMap, скраћено OSM, је бесплатна мапа света која дозвољава приступ географским мапама, као и подацима које те мапе садрже [10]. Основна идеја овог пројекта је да заједница корисника развија и одржава мапе које представљају алтернативу већ постојећим мапама, попут оних које развија Google [13]. Пример OSM мапе на вебу је приказан на слици 5.1.



Слика 5.1: Приказ Београда у *OSM*-у

OSM је 2004. године покренуо Стив Коуст (енг. Steve Coast) са идејом креирања мапа за Уједињено Краљевство. У наредним годинама пројекат је постао глобалан и сада садржи податке целог света [10].

#### 5.1 Елементи

За моделовање података физичког света у оквиру OSM-а се користе OSM елементи [10]. Постоје три врсте елемената и то су чворови (енг. nodes), путање (енг. ways) и релације (енг. relations)

Сваки од елемената може имати придружен један или више тагова (енг. tag) чија је улога да опишу елемент коме припадају. Елементи OSM скупа се могу представити помоћу XML записа од којих је сваки одређен засебним XML тагом [11]. Сваки елемент у XML запису поседује атрибуте који га описују. Постоје одређени атрибути који се налазе у сваком елементу:

*id*, јединствен идентификатор елемента;

user, име корисника који је изменио елемент;

*uid*, идентификатор корисника који је изменио елемент;

timestamp, време последње промене елемента;

visible, знак који показује да ли је елемент видљив;

version, тренутна верзија елемента (почетна вредност је 1 и сваки пут када се изврши модификација елемента тај број се инкрементира);

*changeset*, идентификатор скупа промена у коме је елемент измењен.

#### Тагови

Тагови представљају опис OSM елемента коме припадају. Сваки елемент може имати нула, један или више тагова [10]. Чине га две вредности, кључ, који мора бити јединствен унутар елемента ког таг описује, и вредност. У коду 5.1 је приказан пример тагова у XML формату. Кључ и вредност су означени редом атрибутима k и v. Приказани тагови припадају примеру чвора из кода 5.2 и показују да чвор представља саобраћајни знак.

```
<tag k="name" v="Neu Broderstorf"/>
<tag k="traffic_sign" v="city_limit"/>
```

Ко̂д 5.1: Пример OSM тагова у XML формату

# 5.2 Чворови

Чвор представља локацију на Земљиној површини и састоји се од две координате које представљају географску дужину и ширину [10]. Један чвор се може користити за дефиницију објекта на мапи, попут, на пример, клупе, статуе или фонтане.

У језику *XML* чворови су представљени *XML* тагом *node* унутар ког су угњеждени *OSM* тагови који му припадају. Ко̂д 5.2 представља један чвор записан у *XML* формату. Атрибути *lat* и *lon* представљају координате чвора на мапи. Чвор садржи два тага, који означавају да се на координатама чвора налази саобраћајни знак који представља улазак у насеље *Neu Broderstorf*.

```
<node id="1831881213" version="1" changeset="12370172" lat=
    "54.0900666" lon="12.2539381" user="lafkor" uid="75625"
    visible="true" timestamp="2012-07-20T09:43:19Z">
    <tag k="name" v="Neu Broderstorf"/>
    <tag k="traffic_sign" v="city_limit"/>
    </node>
```

Ко̂д 5.2: XML запис OSM чвора који представља саобраћајни знак

# 5.3 Путање

Путање су уређене листе које садрже између 2 и 20000 чворова и представљају линеарне објекте на мапи, попут путева или река [10]. Такође, могу представљати и разне врсте површина, попут шума. У том случају су први и последњи елемент листе исти чвор.

Путање су у XML формату представљене листом идентификатора чворова које та путања садржи. Сваки чвор путање је записан XML тагом nd са атрибутом ref унутар ког се налази идентификатор чвора. Поред идентификатора чворова, путања може садржати и OSM тагове. XML таг који означава путању је way. У коду 5.3 је приказан пример путање која представља ауто-пут. Унутар OSM тагова путање је записано име улице, као и информација о томе да је ауто-пут једносмеран.

```
<way id="5090250" visible="true" timestamp="2009-01-19
T19:07:25Z" version="8" changeset="816806" user="Blumpsy</pre>
```

```
" uid="64226">
    <nd ref="822403"/>
    <nd ref="21533912"/>
    <nd ref="821601"/>
    <nd ref="1353910"/>
    <nd ref="135791608"/>
    <nd ref="333725784"/>
    <nd ref="333725784"/>
    <nd ref="333725776"/>
    <nd ref="333725776"/>
    <nd ref="823771"/>
    <nd ref="823771"/>
    <tag k="highway" v="residential"/>
    <tag k="name" v="Clipstone Street"/>
    <tag k="oneway" v="yes"/>
    </way>
```

Ко̂д 5.3: XML запис OSM путање која представља ауто-пут

## 5.4 Релације

Релације су структуре које представљају однос између OSM елемената [10]. Могу имати разна значења па су због тога описане таговима. Обично, свака релација поседује OSM таг који се зове type и сваки други таг те релације се интерпретира на основу његове вредности.

У XML формату, релација се означава тагом relation и садржи чланове релације и OSM тагове. Члан је одређен XML тагом member и садржи три атрибута:

type, OSM тип члана, може бити node, way или relation;

*ref*, идентификатор елемента члана;

role, улога члана у релацији.

XML репрезентација релације која представља аутобуску линију приказана је у коду 5.4. У овом примеру, *OSM* чворови који припадају релацији представљају аутобуске станице. Поред чворова, релацији припада и једна путања, која приказује путању аутобуске линије. Тагови релације приказују почетну и завршну локацију линије, као и информације о превознику.

```
<relation id="13092746" visible="true" version="7"</pre>
  changeset="118825758" timestamp="2022-03-23T15:05:48Z"
  user="" uid="">
 <member type="node" ref="5690770815" role="stop"/>
  <member type="node" ref="5751940550" role="stop"/>
  <member type="node" ref="1764649495" role="stop"/>
 <member type="way" ref="96562914" role=""/>
 <member type="way" ref="928474550" role=""/>
 <tag k="from" v="Encre"/>
 <tag k="name" v="9-Montagnes de Guyane"/>
 <tag k="network" v="Agglo'bus"/>
 <tag k="not:network:wikidata" v="Q3537943"/>
 <tag k="operator" v="CACL"/>
 <tag k="ref" v="9"/>
 <tag k="route" v="bus"/>
 <tag k="to" v="Lyce Balata"/>
 <tag k="type" v="route"/>
 </relation>
```

Ко̂д 5.4: XML запис OSM релације која представља аутобуску линију

# Глава 6

# App

# **6.1** Opis

ovde opis appa i sta se trazi od nas

# 6.2 Cloud

шта је cloud и које услуге нуди. EMR, EC2, S3 нпр мало детаљније. За ово или ова секција или одвојена, након дистрибуираних система.

# 6.3 Arhitektura aplikacije

opis komponenti

# 6.4 Подаци

skupovi podataka koji se koriste mada je vecina toga vec napisana ranije, u OSM delu. Dakle OSM + geonames

# 6.5 Obrada OSM skupa Sparkom

koje spark transformacije su primenjene na koje podatke

# 6.6 PolyContains

algoritmi korisceni za poly contains i rezultati (graficki prikaz). mozda zameniti mesta ovoj i prethodnoj sekciji...

# 6.7 Rezultat

dobijeni rezultati aplikacije, prikaz nekih selekcija itd

# Глава 7

# Закључак

zakljucak rada. Takodje, uvod treba da se uradi

# Библиографија

- [1] Bill Chambers and Matei Zaharia. Spark: The definitive guide. 2018.
- [2] Jeffrey Dean and Sanjay Ghemawat. MapReduce: Simplified Data Processing on Large Clusters . 2004. online at: https://research.google/pubs/pub62/.
- [3] Apache foundation. Apache Flume. online at: https://flume.apache.org/.
- [4] Apache foundation. Apache Hive. online at: https://hive.apache.org/.
- [5] Apache foundation. Apache Kafka. online at: https://kafka.apache.org/.
- [6] Apache foundation. Apache Pig. online at: https://pig.apache.org/.
- [7] Apache foundation. Apache Yarn. online at: https://hadoop.apache.org/docs/stable/hadoop-yarn/hadoop-yarn-site/YARN.html.
- [8] Apache foundation. Apache Zookeeper. online at: https://zookeeper.apache.org/.
- [9] Apache foundation. HDFS Architecture Guide. online at: https://hadoop.apache.org/docs/.
- [10] OpenStreetMap Foundation. Openstreetmap wiki. online at: https://wiki.openstreetmap.org/.
- [11] OpenStreetMap Foundation. OSM XML. online at: https://wiki.openstreetmap.org/wiki/OSM\_XML.
- [12] Presto foundation. Presto. online at: https://prestodb.io/.
- [13] Google. Google Maps. online at: https://www.google.com/maps/.

- [14] Arne Horst. Amount of data created, consumed, and stored 2010-2025.
  2021. online at: https://www.statista.com/statistics/871513/worldwide-data-created/.
- [15] Lex Spoon Martin Odersky and Bill Venners. *Programming in Scala, First edition*. 2008.
- [16] Howard Gobioff Sanjay Ghemawat and Shun-Tak Leung. The Google File System. 2003. online at: https://research.google/pubs/pub51/.
- [17] Apache Spark. RDD Programming Guide. online at: https://spark.apache.org/docs/latest/rdd-programming-guide.html.
- [18] Apache Spark. Spark Core. online at: https://spark.apache.org/docs/latest/api/python/reference/pyspark.html.
- [19] Apache Spark. Structured Streaming Programming Guide. online at: https://spark.apache.org/docs/latest/structured-streaming-programming-guide.html.
- [20] Garry Turkington. Hadoop beginner's guide. 2013.
- [21] Garry Turkington and Gabriele Modena. Learning Hadoop 2. 2015.

# Биографија аутора

Вук Стефановић Караџић (*Тршић*, 26. окшобар/6. новембар 1787. — Беч, 7. фебруар 1864.) био је српски филолог, реформатор српског језика, сакупљач народних умотворина и писац првог речника српског језика. Вук је најзначајнија личност српске књижевности прве половине XIX века. Стекао је и неколико почасних доктората. Учествовао је у Првом српском устанку као писар и чиновник у Неготинској крајини, а након слома устанка преселио се у Беч, 1813. године. Ту је упознао Јернеја Копитара, цензора словенских књига, на чији је подстицај кренуо у прикупљање српских народних песама, реформу ћирилице и борбу за увођење народног језика у српску књижевност. Вуковим реформама у српски језик је уведен фонетски правопис, а српски језик је потиснуо славеносрпски језик који је у то време био језик образованих људи. Тако се као најважније године Вукове реформе истичу 1818., 1836., 1839., 1847. и 1852.